

Лабораторная работа 4. Описательный анализ данных

Теоретическая часть

1. Основные статистические параметры

Описательный анализ данных включает в себя расчет основных статистических показателей, которые позволяют определить ключевые характеристики распределения данных.

1.1 Среднее значение (Mean)

- Среднее арифметическое вычисляется как сумма всех значений, деленная на их количество.
- В R используется функция `mean()`:

```
mean(data$column_name)
```

1.2 Медиана (Median)

- Центральное значение отсортированного ряда данных.
- В R вычисляется с помощью `median()`:

```
median(data$column_name)
```

1.3 Дисперсия (Variance) и стандартное отклонение (Standard Deviation)

- Дисперсия показывает степень разброса данных относительно среднего значения.
- Стандартное отклонение является квадратным корнем из дисперсии.
- В R вычисляется с помощью `var()` и `sd()`:

```
var(data$column_name)
```

```
sd(data$column_name)
```

1.4 Квартили и межквартильный размах

- Квартили делят данные на четыре части:
 - Q1 (первый квартиль) – 25%
 - Q2 (медиана) – 50%
 - Q3 (третий квартиль) – 75%
- Межквартильный размах (IQR) – разница между третьим и первым квартилями.
- В R вычисляется с помощью `quantile()` и `IQR()`:

```
quantile(data$column_name)
```

```
IQR(data$column_name)
```

Использование этих показателей помогает получить первичную информацию о наборе данных и выявить возможные выбросы.

2. Функции для описательного анализа в R

R предоставляет широкий набор функций для описательного анализа данных, позволяя быстро получать основные статистические характеристики.

2.1 Основные функции для расчета статистических параметров

- `mean(x)`: вычисляет среднее значение вектора `x`.
- `median(x)`: вычисляет медиану вектора `x`.
- `sd(x)`: вычисляет стандартное отклонение.
- `var(x)`: вычисляет дисперсию данных.
- `summary(x)`: предоставляет краткое описание данных, включая среднее, медиану, минимум, максимум и квартили.
- `quantile(x, probs)`: вычисляет определенные квантили.

Пример использования:

```
x <- c(5, 8, 12, 15, 20)
mean(x) # Среднее значение
sd(x)   # Стандартное отклонение
summary(x) # Общий описательный анализ
```

2.2 Работа с пропущенными значениями

- `is.na(x)`: проверяет наличие пропущенных значений.
- `na.omit(x)`: удаляет строки с пропущенными значениями.
- `complete.cases(x)`: выбирает только полные наблюдения.

Пример обработки пропущенных значений:

```
x <- c(10, NA, 20, 30, NA, 40)
x_clean <- na.omit(x) # Удаление NA-значений
```

2.3 Визуализация описательной статистики

- `boxplot(x)`: строит коробчатую диаграмму (`boxplot`) для визуального анализа данных.
- `hist(x)`: строит гистограмму распределения данных.

Пример построения гистограммы:

```
hist(x, main="Гистограмма распределения", xlab="Значения", col="blue")
```

Эти функции позволяют быстро анализировать данные, выявлять выбросы и понимать их распределение.

Практическая часть

1. Рассчитать основные статистики для данных.
2. Найти пропуски и обработать их.
3. Вывести сводную информацию по набору данных.

Контрольные вопросы

1. Какие функции используются для расчета среднего и медианы?
 2. Как найти минимум и максимум в данных?
 3. Какие функции позволяют визуализировать распределение данных?
 4. Как обработать пропущенные значения?
 5. Как вывести сводную статистику для набора данных?
-