

Лабораторная работа 5. Разведочный анализ данных

Теоретическая часть

1. Методы анализа распределения данных

Анализ распределения данных позволяет понять, как значения переменной распределены в выборке, выявить закономерности, выбросы и определить тип распределения.

1.1 Описательные статистики

- **Среднее (mean)** – показывает центральное значение выборки.
- **Медиана (median)** – разделяет данные на две равные части.
- **Мода (mode)** – наиболее часто встречающееся значение.
- **Дисперсия (variance) и стандартное отклонение (standard deviation)** – характеризуют степень разброса данных относительно среднего.
- **Квартили (quartiles) и межквартильный размах (IQR)** – позволяют определить разброс значений и выявить выбросы.

Пример вычисления в R:

```
summary(data$column)
var(data$column)
sd(data$column)
quantile(data$column, probs = c(0.25, 0.5, 0.75))
```

1.2 Графические методы анализа распределения

- **Гистограмма (histogram)** – показывает частоту встречаемости значений.
- **Ядерная оценка плотности распределения (density plot)** – позволяет оценить сглаженное распределение данных.
- **Коробчатая диаграмма (boxplot)** – помогает выявить выбросы и распределение значений.

Пример построения гистограммы и boxplot в R:

```
hist(data$column, main="Гистограмма", xlab="Значения", col="lightblue",
breaks=20)
boxplot(data$column, main="Boxplot", horizontal=TRUE)
```

1.3 Проверка нормальности распределения

- **Графический метод** – сравнение гистограммы с нормальным распределением.

- **Тест Шапиро-Уилка (Shapiro-Wilk test)** – используется для проверки гипотезы о нормальности данных:

```
shapiro.test(data$column)
```

- **Квантиль-квантиль график (Q-Q plot)** – позволяет визуально оценить отклонение от нормального распределения:

```
qqnorm(data$column)
qqline(data$column, col = "red")
```

1.4 Выявление выбросов

Выбросы – это значения, которые значительно отличаются от остальных наблюдений в выборке. Методы выявления:

- Использование межквартильного размаха (IQR):

```
Q1 <- quantile(data$column, 0.25)
Q3 <- quantile(data$column, 0.75)
IQR <- Q3 - Q1
outliers <- data$column[data$column < (Q1 - 1.5 * IQR) | data$column > (Q3 + 1.5 * IQR)]
```

- Построение boxplot для наглядной идентификации выбросов.

Использование этих методов позволяет глубже понять структуру данных и их распределение, что является важным этапом предварительного анализа.

2. Гистограммы и коробчатые диаграммы

Гистограммы и коробчатые диаграммы являются важными инструментами анализа распределения данных. Они помогают визуализировать структуру данных, выявить выбросы и определить тип распределения.

2.1 Гистограммы (Histogram)

Гистограмма показывает частоту значений переменной в виде столбцов. Это один из самых простых способов понять распределение данных.

- **Создание гистограммы в R:**

```
hist(data$column, main="Гистограмма", xlab="Значения", col="lightblue", breaks=20)
```

- **Параметры функции hist():**
 - main – заголовок графика.

- xlab – подпись оси X.
- col – цвет столбцов.
- breaks – количество интервалов (столбцов).

2.2 Коробчатые диаграммы (Boxplot)

Коробчатая диаграмма (или диаграмма размаха) – это метод отображения распределения данных с помощью медианы, квартилей и выбросов.

- **Создание boxplot в R:**

```
boxplot(data$column, main="Boxplot", horizontal=TRUE, col="orange")
```

- **Параметры функции boxplot():**

- main – заголовок.
- horizontal – горизонтальное расположение.
- col – цвет диаграммы.

2.3 Сравнение гистограмм и boxplot

- Гистограмма показывает распределение частоты значений, но не указывает выбросы.
- Коробчатая диаграмма позволяет определить выбросы и симметрию распределения.

Использование этих методов вместе позволяет получить полную картину о распределении данных.

3. Выбросы в данных

Выбросы (outliers) – это значения, которые значительно отличаются от остальных данных в выборке. Они могут быть результатом ошибок ввода, шумов в данных или реальных аномалий, требующих анализа. Определение и обработка выбросов важны для корректного статистического анализа.

3.1 Методы выявления выбросов

1. **Метод межквартильного размаха (IQR)**

- Вычисление первого (Q1) и третьего (Q3) квартилей.
- Расчет межквартильного размаха ($IQR = Q3 - Q1$).
- Определение выбросов как значений, выходящих за границы:
 - Нижняя граница: $Q1 - 1.5 * IQR$
 - Верхняя граница: $Q3 + 1.5 * IQR$
- Пример в R:

2. `Q1 <- quantile(data$column, 0.25)`

3. `Q3 <- quantile(data$column, 0.75)`

4. `IQR <- Q3 - Q1`
5. `outliers <- data$column[data$column < (Q1 - 1.5 * IQR) | data$column > (Q3 + 1.5 * IQR)]`
6. **Графический анализ (boxplot)**
 - Коробчатая диаграмма помогает визуально определить выбросы.
 - Пример в R:
7. `boxplot(data$column, main="Выбросы в данных")`
8. **Z-оценка (стандартное отклонение)**
 - Выбросы определяются как значения, отклоняющиеся от среднего более чем на 3 стандартных отклонения.
 - Пример в R:
9. `z_scores <- scale(data$column)`
10. `outliers <- data$column[abs(z_scores) > 3]`

3.2 Обработка выбросов

- **Удаление выбросов** – подходит, если выбросы являются ошибками измерения.
- **Замена выбросов на медиану** – помогает сохранить структуру данных.
- **Применение логарифмического преобразования** – уменьшает влияние выбросов на анализ.

Пример замены выбросов на медиану в R:

```
median_value <- median(data$column, na.rm = TRUE)
data$column[data$column < (Q1 - 1.5 * IQR) | data$column > (Q3 + 1.5 * IQR)]
<- median_value
```

Выбросы могут существенно влиять на результаты анализа, поэтому важно правильно их идентифицировать и обрабатывать в зависимости от контекста исследования.

Практическая часть

1. Построить гистограмму и boxplot для данных.
2. Найти выбросы и обработать их.
3. Оценить нормальность распределения.

Контрольные вопросы

1. Какие графики используются для анализа распределения?
2. Как определить выбросы в данных?
3. Какие функции помогают анализировать нормальность?
4. Как вычислить основные моменты распределения?
5. Какие методы устранения выбросов существуют?