

Лабораторная работа 7. Анализ одномерных данных

Теоретическая часть

1. Методы анализа одномерных данных

Анализ одномерных данных (univariate analysis) фокусируется на изучении одной переменной и её распределения, характеристик и закономерностей. Он включает в себя расчет описательных статистик, визуализацию данных и применение статистических тестов.

1.1 Описательная статистика

- Среднее (mean) – центральное значение набора данных.
- Медиана (median) – значение, которое делит данные пополам.
- Мода (mode) – наиболее часто встречающееся значение.
- Дисперсия (variance) и стандартное отклонение (standard deviation) – степень разброса данных.
- Квартили и межквартильный размах (IQR) – для оценки распределения и выбросов.

Пример вычисления в R:

```
summary(data$column)
mean(data$column)
var(data$column)
sd(data$column)
quantile(data$column, probs = c(0.25, 0.5, 0.75))
```

1.2 Графические методы анализа

- Гистограмма (histogram) – отображает частоту значений переменной.
- Boxplot (коробчатая диаграмма) – помогает выявить выбросы и асимметрию распределения.
- Q-Q plot – проверяет соответствие распределения нормальному.

Пример построения графиков в R:

```
hist(data$column, main="Гистограмма", xlab="Значения", col="blue")
boxplot(data$column, main="Boxplot")
qqnorm(data$column)
qqline(data$column, col="red")
```

1.3 Проверка гипотез о распределении

- Тест Шапиро-Уилка (Shapiro-Wilk test) – проверяет нормальность распределения.
- Критерий Колмогорова-Смирнова (Kolmogorov-Smirnov test) – тестирует соответствие данных заданному распределению.

Пример в R:

```
shapiro.test(data$column)
ks.test(data$column, "pnorm")
```

Анализ одномерных данных позволяет глубже понять структуру данных и определить их ключевые характеристики перед проведением более сложных исследований.

2. Корреляция и регрессия

Корреляция и регрессия – это методы статистического анализа, которые используются для оценки взаимосвязи между переменными.

Корреляционный анализ показывает степень связи между переменными, а регрессионный анализ позволяет предсказать значение одной переменной на основе другой.

2.1 Корреляция

Корреляция измеряет силу и направление связи между двумя переменными. В R используется несколько коэффициентов корреляции:

- Корреляция Пирсона (Pearson) – оценивает линейную зависимость между переменными.
- Корреляция Спирмена (Spearman) – оценивает монотонную зависимость, не требующую нормального распределения данных.
- Корреляция Кендалла (Kendall) – подходит для ранговых данных.

Пример вычисления коэффициента корреляции в R:

```
correlation_pearson <- cor(data$x, data$y, method="pearson")
correlation_spearman <- cor(data$x, data$y, method="spearman")
correlation_kendall <- cor(data$x, data$y, method="kendall")
```

2.2 Регрессионный анализ

Регрессионный анализ используется для прогнозирования значений одной переменной на основе другой. Основные виды регрессии:

- Линейная регрессия – модель вида $y = a + bx$, где a – свободный член, b – коэффициент наклона.

- Множественная регрессия – учитывает несколько предикторов.
- Логистическая регрессия – применяется для предсказания категориальных переменных.

Пример построения линейной регрессии в R:

```
model <- lm(y ~ x, data=data)
summary(model)
```

2.3 Интерпретация регрессионной модели

- Коэффициент детерминации (R^2) – показывает, какая доля вариации зависимой переменной объясняется предиктором.
- p-value – указывает на значимость предиктора в модели.
- Остатки модели – разница между предсказанными и фактическими значениями, анализируются для проверки качества модели.

Графическое представление линейной регрессии в R:

```
plot(data$x, data$y)
abline(model, col="red")
```

Использование корреляции и регрессии помогает выявить зависимости в данных и строить прогнозные модели.

Практическая часть

1. Рассчитать корреляцию между переменными.
2. Построить регрессионную модель.

Контрольные вопросы

1. В чем разница между корреляцией и регрессией?
 2. Какие типы корреляции существуют?
 3. Как интерпретировать коэффициент детерминации?
 4. Какие функции используются для линейной регрессии?
 5. Как проверить значимость регрессионной модели?
-